

字节校招面试汇总（2025）

一、大模型

一面

1. 自我介绍，问实习和论文
2. 看你实习微调过Qwen2，说说Qwen2的模型结构吧，Qwen2相比Qwen1做了哪些改进
3. 为什么现在 Decoder - only 成为大模型的主流架构，相比于 Encoder - Decoder 的架构好在哪里
4. 讲一下 RoPE 吧，目前常用的位置编码还有哪些，RoPE 有什么优点（相对位置、外推性……），如何进一步外推
5. 为什么有了 SFT 之后还需要 RLHF
6. PPO和 DPO 的主要思想是什么，DPO 相比 PPO 的 RLHF 做了哪些改进，除此之外还知道哪些 RL 算法，知道 DeepSeek 的 GRPO 吗
7. 代码：23. 合并 K 个升序链表

二面

8. 自我介绍，选一个做的好的实习或者论文讲一下，这里问的比较细，动机是什么，为什么用当前的方案
9. 了解 KV cache 吗，GQA 的思想是什么
10. 讲一下 FlashAttention 的思想和做法
11. 除了刚刚说到的这些，还了解过哪些模型训练推理优化的方法（DeepSpeed，数据并行，张量并行，流水线并行……
12. 开放题：如果要提升大模型的多轮对话能力，你有哪些可以改进的点
13. 代码：刚刚提到了 GQA，写一下 GQA 吧

三面：

14. 自我介绍，过实习和论文，这里面试官会穿插问一些八股的知识，比如了解 Qwen 的结构吗，微调的数据配比是怎样的
15. 大模型的灾难性遗忘问题怎么解决
16. 了解 RAG 吗，GraphRAG 的做法
17. 场景题：目前有一些专业领域知识，比如医疗知识或者法律条文，准备做一个智能助手，要让你搭建一个 RAG 链路，会怎么做
18. 开放题：用过豆包吗，觉得目前豆包还存在什么问题

19. 代码：416. 分割等和子集

内容来源：小红书[大模型师兄](#)

二、多模态大模型

一面

1. 深挖多模态论文（主要是基于transformer的架构）
2. 介绍transformer架构
3. 详细说一下Decoder的因果注意力QKV分别来自哪
4. Attention为什么要做scaled不做会怎么样为什么用根号d_k
5. Transformer怎么做加速训练（KV缓存）训练和推理有什么区别（并行化）
6. 深挖多模态大模型论文用的video-llama讲一下大模型的结构
7. 论文用了CoT讲一下论文的CoT是怎么样的微调用的LoRA介绍一下LoRA
8. LoRA初始化怎么做的用的秩是多少为什么不选其他的数
9. 知道deepspeed和megatron吗分别介绍一下
10. 论文用的deepspeed详细讲了一下三个stage分别是什么

二面

11. 深挖多模态和大模型的论文
12. Decoder文本生成有哪几种方法
13. 还知道哪些多模态大模型
14. 介绍一下ALBEF、BLIP
15. BLIP2的结构是什么两阶段怎么训练的有哪些损失
16. 知道PEFT吗讲一下LoRA还有什么微调方法
17. prefix-tuning和Ptuning 两者分别是怎么做的为了解决什么提出的后面就是一些场景题

三面

18. 深挖论文
19. 讲一下multi-head attention
20. 用pytorch手撕一下要可以实现crossattention的
21. 讲一下你用的大模型是什么结构特征是怎么喂给大模型的
22. 大模型训练为什么不用SFT
23. LoRA是什么有什么好处

24. 知道RLHF吗讲一下训练流程

25. 接下来就是好几个场景题电商相关的用大模型解决prompt应该怎么设计怎么处理

26. prompt的输出怎么过滤错误格式的输出

内容来源：小红书[archive](#)

三、算法

一面

1. 自我介绍，问实习和论文
2. 看你实习微调过Qwen2，说说Qwen2的模型结构吧，Qwen2相比Qwen1做了哪些改进
3. 为什么现在 Decoder - only 成为大模型的主流架构，相比于 Encoder - Decoder 的架构好在哪里
4. 讲一下 RoPE 吧，目前常用的位置编码还有哪些，RoPE 有什么优点（相对位置、外推性……），如何进一步外推
5. 为什么有了 SFT 之后还需要 RLHF
6. PPO和 DPO 的主要思想是什么，DPO 相比 PPO 的 RLHF 做了哪些改进，除此之外还知道哪些 RL 算法，知道 DeepSeek 的 GRPO 吗
7. 代码：23. 合并 K 个升序链表

二面

8. 自我介绍，选一个做的好的实习或者论文讲一下，这里问的比较细，动机是什么，为什么用当前的方案
9. 了解 KV cache 吗，GQA 的思想是什么
10. 讲一下 FlashAttention 的思想和做法
11. 除了刚刚说到的这些，还了解过哪些模型训练推理优化的方法（DeepSpeed，数据并行，张量并行，流水线并行……
12. 开放题：如果要提升大模型的多轮对话能力，你有哪些可以改进的点
13. 代码：刚刚提到了 GQA，写一下 GQA 吧

三面：

14. 自我介绍，过实习和论文，这里面试官会穿插问一些八股的知识，比如了解 Qwen 的结构吗，微调的数据配比是怎样的
15. 大模型的灾难性遗忘问题怎么解决
16. 了解 RAG 吗，GraphRAG 的做法
17. 场景题：目前有一些专业领域知识，比如医疗知识或者法律条文，准备做一个智能助手，要让你搭建一个 RAG 链路，会怎么做

18. 开放题：用过豆包吗，觉得目前豆包还存在什么问题

19. 代码：416. 分割等和子集

内容来源：小红书 [薛定谔的offer猫](#)

四、大模型

一面

1. 聊项目。
2. AUC的两种公式是？你能证明这两种等价的吗？
3. BERT-CRF中，为什么要加CRF？好处是？
4. self-attention为什么要用QKV三个矩阵，不用有什么问题？有没有哪个模型的Q和K矩阵是一样的？
5. reinforce属于on-policy还是off-policy？为什么？
6. reinforce带上baseline好处是？reinforce的loss写一下？
7. 策略梯度会推导吗？简单写一下？
8. 代码题（代码题一般别着急写，先跟面试官说下思路，确定了再写）：lc 46，全排列（lc表示leetcode，下同）。lc 73，矩阵置0。

二面

9. 介绍项目。
10. 知识蒸馏有哪几种？你觉得哪种效果最好？
11. nlp的数据增强方法，主要有哪几种？每一种举个例子？
12. 分类的损失函数为什么是交叉熵而不是mse？
13. BERT对输入文本的长度有什么限制，为什么要限制长度呢？
14. BigBird里面有哪几种注意力机制？相比原始transformer的self-attention的优势？
15. 场景题：如何根据拼多多的商品数量，估计淘宝的商品数量？
16. 给出emb_size, max_len, vocab_size, ff_inner_size, num_heads, 12层，求BERT参数量。
17. 代码题：n皇后问题。

三面

18. 简单聊项目。
19. CRF和HMM区别？CRF为什么比HMM效果好？
20. 如果BERT词表很大，比如vocab_size达到几百万，怎么办？
21. 快速手写一些transformer的mha（多头注意力），伪代码意思一下就行。

22. 为什么对比学习中，temperature很小，而知识蒸馏的temperature比较大？
23. 你觉得在抖音买东西，和淘宝、拼多多他们的区别是？（我没在抖音买过，就只能现场编。）
24. 你最近看到过哪些paper？简单介绍下？
25. 你觉得自己有那些优缺点？平时喜欢怎么缓解压力？

内容来源：小红书[薛定谔的offer猫](#)

五、大模型

1. 请简要介绍您的技术背景，重点说明与大模型相关的项目经验。
2. 请详细说明Transformer的整体架构及其核心组成部分。
3. 为什么Attention公式中要除以 $\sqrt{d_k}$ ？这个操作有什么作用？
4. Transformer训练过程中为什么容易出现梯度消失或爆炸问题？
5. 在监督微调(SFT)过程中遇到过哪些典型问题？请分享您的解决方案和实践经验。
6. 在构建领域大模型时，如何确定不同领域数据的配比比例？有哪些考量因素？
7. 为什么当前主流LLM都采用Decoder-only架构？这种结构相比Encoder-Decoder有哪些优势？
8. ADAM优化器相比SGD有哪些改进？
9. 请简要说明梯度下降的原理
10. ADAM是如何在SGD基础上进行优化的？
11. 代码题；给定一个元素互不相同的整数数组nums，编写函数返回其所有可能的子集（幂集）。

内容来源：小红书[老王聊AI](#)