

阿里校招面试汇总（2025）

一、大模型

自我介绍 + 做过的项目，项目问的很细

1. 项目中遇到的最大的困难，如何解决？
2. CLIP原理，损失函数，对比学习的思想 算法基础：对比学习
3. Qwen-VL了解吗，数据处理怎么做，训练过程？ MLLM模型
4. BLIP基于ALBEF做了哪些改进，BLIP2,BLIP3 MLLM模型
5. LLAVA怎么做的，和BLIP,Qwen-VL的区别 MLLM模型
6. 多模态的RLHF怎么做？ RLHF
7. 多模态embedding了解吗？ 编码器
8. 实现一下对比学习的损失InfoNCE 算法基础：损失函数

手撕

9. 零钱兑换2 力扣-数组题解

内容来源：小红书[草莓师姐](#)

二、大模型

1. 什么是prefill
2. 介绍softmax，介绍transformer，详细介绍QKV过程
3. 有哪些降低transformer训练时间复杂度的工作？
4. 如何解决长下文问题？
5. GQA原理，如何实现
6. LLM为什么是only-Decoder架构，为什么不采用T5架构
7. lora原理
8. kv cache原理
9. 讲实习，讲论文，讲科研项目
10. 场景题：怎么使用LLM解决他们的业务问题（电商相关）
11. 手撕：无重复字符最长子串，排序链表

内容来源：小红书[史迪崽崽](#)

三、多模态大模型

一面

1. 首先是自我介绍和过项目，面试官还一起探讨项目用到的方法，可行性之类的
2. 介绍一下 CLIP
3. 了解 LoRA 吗，LoRA 微调的原理是什么
4. 了解哪些多模态大模型，简要介绍几个
5. BLIP 的三个损失函数分别是什么，数据是怎样清洗的
6. BLIP2 相对于 BLIP 有哪些改进，BLIP3 又有哪些改进
7. Qwen-VL 的三个训练流程分别是什么，有什么作用
8. 视觉编码器和 LLM 连接时，使用 BLIP2 中 Q-Former 那种复杂的 Adaptor 好还是 LLaVA 中简单的 MLP 好，说说各自的优缺点
9. 代码：实现多头自注意力

二面

10. 自我介绍和过项目，简要问了项目中使用某些方法的动机，以及是否会导致其他的问题
11. 了解 Transformer 吗，编码器和解码器的注意力有什么区别，在计算注意力中时除以 $\sqrt{d_k}$ 的原因是什么
12. 后来有哪些比较经典的基于 Transformer 的语言模型，Qwen 相比于原始 Transformer 有哪些结构上的改动，Qwen2 又有哪些改进
13. 了解 RLHF 吗，DPO 和 PPO 有什么区别，Loss 是什么样的，各自的优缺点是什么
14. 介绍一下 CLIP，还了解什么其他的对比学习方法
15. 开放题：了解哪些多模态大模型，目前多模态大模型最大的问题是什么
16. 代码：1143. 最长公共子序列

三面

17. 自我介绍，然后详细过了一下项目
18. 了解哪些大模型和多模态大模型，然后就聊了大模型这一路是怎么发展过来的，Transformer、BERT、GPT、LLaMA、Qwen 这些，以及当时的 o1 推理模型
19. 平常有尝试过训练过大模型吗，规模小一点的也没关系

内容来源：小红书[算法小甜](#)

四、大模型

1. 自我介绍：请简要介绍您的技术背景，重点说明与大模型应用相关的项目经验，并突出您在搜索推荐场景下的技术贡献。
2. 简历项目深挖：请选择简历中与AI模型最相关的项目，详细说明业务目标、技术方案（如模型选型、优化策略）及最终量化效果。
3. GPT核心原理：从模型架构和训练目标角度，解释GPT系列模型的自回归生成机制，并说明其与BERT等模型的本质区别。
4. 扩散模型理解：阐述扩散模型的前向过程和反向过程，并分析其在生成质量与训练稳定性方面的优势。
5. 模型微调资源需求：全参数微调一个7B参数的模型需要多少显存？请说明显存估算方法，并列举需要保存的关键参数（如模型权重、优化器状态等）。
6. ViT架构解析：解释Vision Transformer的核心设计，包括图像分块、位置编码等关键组件，并对比其与CNN的优劣势。
7. CLIP优化方案：CLIP模型的zero-shot能力是如何实现的？如何通过提示工程或微调策略进一步提升其跨模态检索效果？
8. 归一化层实现：写出BatchNorm和LayerNorm的完整计算公式，并分析它们在训练动态和适用场景上的差异。

内容来源：小红书[小林大模型](#)

五、大模型应用

一面

1. 自我介绍，问实习、论文或工作经验。
2. 手推Multi - Head Attention计算过程，并解释淘宝搜索排序中如何利用注意力机制？
3. 对比BERT和GPT的架构差异，淘天哪些业务适合用BERT？哪些适合GPT？
4. 位置编码在电商搜索场景中的作用（如用户长Query的语义理解）。
5. 如何优化Transformer的长文本处理能力？
6. 在淘天商品标题生成任务中，如何设计Prompt让大模型输出合规文案？
7. 解释LoRA的适配器设计，如何将其应用于淘宝评论情感分析模型？
8. 大模型在训练中遇到显存溢出（OOM）如何解决？(梯度检查点、ZeRO-3)
9. 如何用DPO优化淘宝客服对话模型的偏好对齐？

二面

10. 依旧自我介绍，问实习、论文或工作经验。
11. 为什么选择淘天？对电商AI的未来有什么看法？

12. 如何用大模型提升淘宝搜索的Query理解? (同义词扩展、意图识别)
13. 设计一个多模态商品推荐模型 (文本 + 图片), 如何融合特征?
14. 大模型如何解决推荐系统的冷启动问题?
15. 如何用Deepspeed在百亿参数模型上实现高效分布式训练?
16. 解释混合精度训练在淘天GPU集群中的应用, 遇到NaN怎么调试?
17. 实现一个带Cache的自回归生成函数。
18. 用PyTorch编写LoRA微调的简化版代码。

内容来源: 小红书[白白说大模型](#)